

UNIVERSITÉ DE YAOUNDÉ

I

ÉCOLE NATIONALE
SUPÉRIEURE
POLYTECHNIQUE

DÉPARTEMENT DE GÉNIE
INFORMATIQUE



UNIVERSITY OF YAOUNDE

I

NATIONAL ADVANCED
SCHOOL
OF ENGINEERING

DEPARTMENT OF
COMPUTER
ENGINEERING

OTA — TRANSPORT OPTIMAL POUR LA DÉTECTION D'OBJETS

Ge et al. (CVPR 2021)

Carnet de lecture / Projet de Machine Learning avancé

Présenté par :

BISSOG SAMUEL DURAND

Matricule : 20P125

BOURMEKE KIMAKA JUNIOR DIMITRI

Matricule : 20P232

KEUMOUO TADAHU DIROIL JAMES

Matricule : 20P172

(Groupe 2 — OTA : Transport Optimal pour la détection d'objets)

Sous la supervision de :

Dr Hyppolyte Tapamo

Chargé de cours, UY1

Année académique : **2025–2026**

Article lu

Ge et al., *OTA : Optimal Transport Assignment for Object Detection*, CVPR 2021.

Idée clé : l'assignation de labels (quelle ancre est positive pour quel objet) est formulée comme un **transport optimal** global sur toute l'image, plutôt que des règles locales par objet (IoU, aire, distance au centre).

Questions initiales

- Pourquoi l'assignation *indépendante par objet* échoue-t-elle lorsque deux objets se chevauchent ?
- En quoi le transport optimal diffère-t-il de l'algorithme hongrois utilisé dans DeTR (un-à-un vs un-à-plusieurs) ?
- Comment Sinkhorn-Knopp permet-il de résoudre le problème à grande échelle sans solveur LP complet ?
- Que signifie une ancre « ambiguë » et pourquoi les heuristiques Min Area / Max IoU sont insuffisantes ?

Points clarifiés

- Chaque **gt** est un *fournisseur* de k_i labels positifs ; chaque **ancre** est un *demandeur* ($d_j = 1$) ; le **fond** fournit les labels négatifs restants.
- Le coût unitaire est $\mathcal{L}_{\text{cls}} + \alpha \mathcal{L}_{\text{reg}}$ (Eq. 2 de l'article) ; le fond n'a qu'un coût de classification.
- **Dynamic k** : somme des q plus grandes IoU prédites par gt — adapte le nombre de positifs à la taille/forme de l'objet.
- **Center Prior** : seules les r^2 ancres les plus proches du centre de chaque gt sont éligibles au début de l'entraînement.
- **Ambiguïté OTA** : $\max_i \pi_{ij}^* < 0.9$ — le plan de transport ne tranche pas nettement ; critère plus sensible que les heuristiques à seuil dur.
- Sinkhorn-Knopp régularise le LP par entropie ($\gamma = 0.1$, $T = 50$ itérations dans l'article) ; notre validation montre un écart $< 1\%$ au LP exact pour $\gamma = 0.1$.

Choix de conception du groupe

- **Implémentation** fidèle en Python/NumPy/SciPy : `sinkhorn_knopp`, `build_cost_matrix`, `dynamic_k_estimation`, baselines Min Area / Max IoU / Min Loss.
- **Validation** : comparaison numérique à `scipy.optimize.linprog` (8 essais, écart relatif 0,16–0,73 %).
- **Expérience** : scénario synthétique (2 objets qui se chevauchent, 625 ancres) faute de GPU/PyTorch/COCO — honnêtement documenté dans le rapport.
- **Non reproduit** : entraînement FCOS-ResNet-50 sur COCO (AP 40,7 % de l'article) — hors portée matérielle en 1 jour ; perspective future dans le rapport.

Limites et perspectives

L'implémentation couvre l'*algorithme d'assignation*, pas le pipeline de détection complet. Les coûts cls/reg de l'expérience synthétique sont simulés (scores décroissants avec la distance au centre), pas issus d'un réseau entraîné. Piste prioritaire : brancher OTA sur un détecteur PyTorch + COCO dès qu'un GPU est disponible.

Code et résultats reproductibles : <https://github.com/akamik237/ota-groupe2-enspy>