

UNIVERSITÉ DE YAOUNDE

I

ÉCOLE NATIONALE
SUPÉRIEURE
POLYTECHNIQUE

DÉPARTEMENT DE GÉNIE
INFORMATIQUE



UNIVERSITY OF YAOUNDE

I

NATIONAL ADVANCED
SCHOOL
OF ENGINEERING

DEPARTMENT OF
COMPUTER
ENGINEERING

OTA — ASSIGNATION DE LABELS PAR TRANSPORT OPTIMAL

Implémentation Sinkhorn-Knopp et validation algorithmique

Rapport scientifique / Projet de Machine Learning avancé

Présenté par :

BISSOG SAMUEL DURAND

Matricule : 20P125

BOURMEKE KIMAKA JUNIOR DIMITRI

Matricule : 20P232

KEUMOUO TADAH DIROIL JAMES

Matricule : 20P172

(Groupe 2 — OTA : Transport Optimal pour la détection d'objets)

Sous la supervision de :

Dr Hyppolyte Tapamo

Chargé de cours, UY1

Année académique : **2025–2026**

Résumé

Ce rapport étudie en profondeur **OTA** (*Optimal Transport Assignment*) [3], une méthode d’assignation de labels pour l’entraînement de détecteurs d’objets qui reformule un problème historiquement résolu par des règles heuristiques (IoU, aire, distance au centre) comme un problème de *Transport Optimal* résolu par l’itération de Sinkhorn-Knopp [2]. Nous formalisons le problème du transport optimal, détaillons la construction de la matrice de coût $\text{cls} + \text{reg}$, l’estimation dynamique du nombre de labels positifs par objet (*Dynamic k*) et le *Center Prior*, puis fournissons une implémentation fidèle en Python/NumPy/SciPy de l’algorithme complet (Algorithme 1 de l’article). Cette implémentation est validée de deux façons indépendantes : (i) comparaison numérique de l’itération de Sinkhorn-Knopp à la solution exacte d’un programme linéaire (`scipy.optimize.linprog`) sur des problèmes de transport aléatoires, avec un écart relatif inférieur à 1 % pour les paramètres de l’article ; (ii) une expérience synthétique contrôlée reproduisant qualitativement le phénomène central de l’article (la gestion des *ancres ambiguës*), comparant OTA aux heuristiques Min Area, Max IoU et Min Loss. **Avertissement essentiel** : faute d’accès à un GPU, à un framework de deep learning (PyTorch/TensorFlow) et à un accès réseau vers le jeu de données COCO dans l’environnement d’exécution utilisé pour ce projet, nous *ne reproduisons pas* l’entraînement d’un détecteur FCOS complet sur COCO et *ne prétendons donc pas* reproduire les scores d’AP de l’article (Tableaux 1 à 6 de [3]). Ce rapport se concentre sur ce qui est le cœur scientifique du sujet et reste pleinement vérifiable dans cet environnement : l’algorithme d’assignation lui-même, sa correction numérique, et son comportement qualitatif face à l’ambiguïté — avec des résultats synthétiques réels, non fabriqués, et honnêtement présentés comme tels.

Table des matières

1	Introduction	3
1.1	Contexte	3
1.2	Problématique	3
1.3	Contribution d’OTA	3
1.4	Objectifs et structure du rapport	3
2	État de l’art	4
2.1	Assignation statique	4
2.2	Assignation dynamique	4
2.3	Vers une assignation globale	4
2.4	Positionnement de ce rapport	4
3	Concepts théoriques	5
3.1	Le problème du transport optimal	5
3.2	Régularisation entropique et itération de Sinkhorn-Knopp	5
4	Description détaillée de la méthode (OTA)	6
4.1	Formulation du problème d’assignation comme transport optimal	6
4.2	Coût de transport (Eq. 2 de l’article)	6
4.3	Le fond comme fournisseur supplémentaire (Eq. 3-4)	6
4.4	Estimation dynamique de k (<i>Dynamic k Estimation</i>)	6
4.5	Center Prior	6
4.6	Décodage de l’assignation	7
4.7	Traitement des ancres ambiguës	7
4.8	Algorithme complet	7

5	Implémentation	7
5.1	Structure du code	7
5.2	Extrait : itération de Sinkhorn-Knopp	8
5.3	Validation par comparaison à un solveur exact	8
6	Expérimentations	8
6.1	Validation numérique de Sinkhorn-Knopp	8
6.2	Compromis γ / nombre d'itérations	8
6.3	Scénario synthétique d'ancres ambiguës	9
7	Résultats	9
7.1	Dynamic k et nombre d'ancres ambiguës	9
7.2	Lecture des résultats	10
8	Analyse critique	11
8.1	Fidélité par rapport à l'article original	11
8.2	Limites de la méthode (et de notre validation)	11
8.3	Pistes d'amélioration	11
9	Conclusion	12

1 Introduction

1.1 Contexte

Les détecteurs d’objets modernes fondés sur des réseaux convolutifs (RetinaNet [7], FCOS [12], Faster R-CNN [9]) effectuent une prédiction dense : pour un grand nombre d’ancres (boîtes ou points prédéfinis), le réseau prédit une classe et une régression de boîte. Avant l’entraînement, il faut décider, pour chaque ancre, si elle doit être considérée comme un exemple positif (associé à un objet donné) ou négatif (fond) — c’est la procédure d’*assignation de labels* (*label assignment*).

1.2 Problématique

Les stratégies historiques (seuil d’IoU [9, 7], région centrale de l’objet [12]) sont *statiques* et *indépendantes par objet* : chaque objet vérité-terrain (gt) est traité séparément, sans tenir compte du contexte global de l’image. Or, lorsque deux objets sont proches ou se chevauchent (scènes de foule, occlusions), certaines ancres deviennent *ambiguës* : elles sont des candidates positives plausibles pour plusieurs gt simultanément. Assigner arbitrairement une telle ancre à l’un des objets peut introduire un gradient nuisible pour les autres objets concurrents. Les méthodes dynamiques récentes (ATSS [15], PAA [5], FreeAnchor [16]) améliorent le choix du seuil pos/neg *par objet*, mais restent, elles aussi, locales : elles ne considèrent jamais l’assignation comme un problème *global* sur l’ensemble de l’image.

1.3 Contribution d’OTA

OTA [3] propose de formuler l’assignation de labels comme un problème de **Transport Optimal** : chaque objet vérité-terrain est vu comme un *fournisseur* qui propose un certain nombre de labels positifs, chaque ancre comme un *demandeur* qui a besoin d’exactly un label, et le *coût de transport* unitaire entre un objet et une ancre est la perte (classification + régression) que cette assignation induirait. Résoudre le transport optimal — c’est-à-dire minimiser le coût total de transport sous les contraintes d’offre et de demande — revient alors à trouver l’assignation *globalement optimale* sur l’ensemble de l’image, contrairement aux méthodes gt-par-gt. Le problème de transport optimal étant, sous forme brute, un programme linéaire coûteux à grande échelle, les auteurs le résolvent efficacement par l’itération de Sinkhorn-Knopp [2], qui régularise le problème par un terme entropique et le résout par des multiplications matricielles itératives, parallélisables sur GPU.

1.4 Objectifs et structure du rapport

Conformément au cadrage académique de ce travail, ce rapport :

- explique le problème traité et son contexte scientifique (section 2) ;
- présente les concepts théoriques nécessaires — transport optimal, régularisation entropique, itération de Sinkhorn-Knopp (section 3) ;
- détaille la méthodologie d’OTA étape par étape, avec ses équations (section 4) ;
- fournit une implémentation fidèle et testée (section 5) ;
- teste cette implémentation et compare ses résultats à ceux attendus (sections 6 et 7) ;
- discute limites et pistes d’amélioration (section 8).

Avertissement méthodologique (à lire avant toute chose). L’environnement d’exécution utilisé pour ce projet ne dispose *ni* de GPU, *ni* de PyTorch/TensorFlow, *ni* d’un accès réseau vers COCO [8] ou CrowdHuman [11]. Entraîner un FCOS-ResNet-50 sur COCO comme dans l’article (90k à 180k itérations, 8 GPU) est donc totalement hors de portée de cet environnement. Nous l’indiquons explicitement, conformément à l’exigence de ne pas inventer de

résultats : les Tableaux 1, 2, 3, 4, 5, 6 de l'article original ne sont pas reproduits dans ce rapport. À la place, nous concentrons l'effort de vérification et d'expérimentation sur ce qui constitue le véritable objet du sujet — l'algorithme d'assignation par transport optimal lui-même — via (a) une validation numérique rigoureuse de l'itération de Sinkhorn-Knopp contre un solveur de programmation linéaire exact, et (b) une expérience synthétique contrôlée reproduisant qualitativement la Figure 1, la Figure 3 et le Tableau 2 de l'article (gestion des ancres ambiguës), avec des coûts cls/reg simulés (et documentés comme tels) en l'absence d'un réseau réellement entraîné.

2 État de l'art

2.1 Assignation statique

Les détecteurs à ancres comme Faster R-CNN [9] ou RetinaNet [7] utilisent un seuil d'IoU fixe (par exemple 0.7/0.3) pour séparer positifs et négatifs. Les détecteurs sans ancre comme FCOS [12] considèrent les points dans la région centrale de la boîte comme positifs. Dans les deux cas, le critère est *identique pour tous les objets*, quelle que soit leur taille, leur forme ou leur niveau d'occlusion.

2.2 Assignation dynamique

ATSS [15] calcule un seuil IoU adaptatif par objet à partir de statistiques (moyenne + écart-type) sur un ensemble d'ancres proches. PAA [5] modélise la distribution jointe des pertes positives/négatives par un mélange de Gaussiennes (GMM) pour en déduire la frontière pos/neg. FreeAnchor [16] construit un ensemble de candidats par IoU puis optimise une vraisemblance dédiée à la détection. AutoAssign [17] rend l'assignation entièrement différentiable et data-driven. Toutes ces méthodes améliorent le choix du seuil *par objet*, mais restent locales : elles ne considèrent jamais explicitement le contexte des *autres* objets de l'image lors de la décision.

2.3 Vers une assignation globale

DeTR [1] est la première méthode à envisager l'assignation sous un angle global, via l'algorithme hongrois [6] qui trouve un appariement bijectif optimal (un-à-un) entre requêtes et objets. Mais ce mode un-à-un ne convient pas aux détecteurs convolutifs classiques, où chaque objet est typiquement associé à *plusieurs* ancres positives (un-à-plusieurs), ce qui contribue à l'efficacité de l'entraînement. OTA [3] comble ce manque : c'est, à la connaissance des auteurs de l'article, la première méthode à formuler l'assignation *un-à-plusieurs* comme un problème d'optimisation globale sur toute l'image, via le transport optimal. LLA [4], des mêmes auteurs, explore une piste apparentée (*loss-aware label assignment*) spécifiquement pour la détection de piétons en foule.

2.4 Positionnement de ce rapport

Ce travail se concentre sur la formalisation, l'implémentation et la validation *algorithmique* d'OTA — la résolution du problème de transport optimal par Sinkhorn-Knopp, la construction du coût, le Center Prior et le Dynamic k — plutôt que sur la reproduction de ses performances de détection sur un jeu de données à grande échelle, pour les raisons d'environnement documentées en introduction.

3 Concepts théoriques

3.1 Le problème du transport optimal

Définition 1 (Transport optimal, forme discrète). Soit m fournisseurs disposant chacun de s_i unités de biens ($i = 1, \dots, m$) et n demandeurs ayant chacun besoin de d_j unités ($j = 1, \dots, n$), avec $\sum_i s_i = \sum_j d_j$. Soit c_{ij} le coût de transport d'une unité du fournisseur i vers le demandeur j . Le problème du transport optimal [13] consiste à trouver un plan de transport $\pi^* = \{\pi_{ij}\}$ minimisant le coût total :

$$\min_{\pi} \sum_{i=1}^m \sum_{j=1}^n c_{ij} \pi_{ij} \quad \text{s.c.} \quad \sum_j \pi_{ij} = s_i, \quad \sum_i \pi_{ij} = d_j, \quad \pi_{ij} \geq 0.$$

C'est un programme linéaire, soluble en temps polynomial par des méthodes génériques (simplexe, points intérieurs), mais dont la taille (le nombre de variables π_{ij}) croît comme le produit $m \times n$, ce qui devient coûteux lorsque n (le nombre d'ancres, potentiellement des dizaines de milliers par image) est grand.

3.2 Régularisation entropique et itération de Sinkhorn-Knopp

Cuturi [2] propose de régulariser le problème par un terme d'entropie $E(\pi_{ij}) = \pi_{ij}(\log \pi_{ij} - 1)$, pondéré par $\gamma > 0$:

$$\min_{\pi} \sum_{i,j} c_{ij} \pi_{ij} + \gamma E(\pi_{ij}).$$

La résolution par multiplicateurs de Lagrange (cf. Annexe A.1 de [3], reproduite en détail ci-dessous) montre que la solution optimale prend la forme séparable

$$\pi_{ij}^* = u_j M_{ij} v_i, \quad M_{ij} = \exp(-c_{ij}/\gamma),$$

où $u \in \mathbb{R}^n$ et $v \in \mathbb{R}^m$ sont déterminés par les contraintes marginales. Ce système se résout par les mises à jour itératives (l'itération de Sinkhorn-Knopp)

$$u_j^{t+1} = \frac{d_j}{\sum_i M_{ij} v_i^t}, \quad v_i^{t+1} = \frac{s_i}{\sum_j M_{ij} u_j^{t+1}},$$

qui ne consistent qu'en des produits matrice-vecteur, très efficacement parallélisables (GPU), et convergent vers $\pi^* = \text{diag}(v) M \text{diag}(u)$.

Proposition 1 (Comportement aux limites de γ). Lorsque $\gamma \rightarrow 0^+$, la solution régularisée π_{γ}^* converge vers la solution du programme linéaire exact (transport optimal non régularisé). Lorsque $\gamma \rightarrow +\infty$, π_{γ}^* tend vers le plan de transport indépendant du coût, déterminé uniquement par les contraintes marginales (produit extérieur normalisé de s et d).

Cette propriété explique le compromis pratique : un γ petit donne un plan proche de l'optimum exact (donc une assignation quasi-déterministe, cf. section 6), mais ralentit la convergence numérique de l'itération (les matrices $M_{ij} = \exp(-c_{ij}/\gamma)$ deviennent très contrastées) ; un γ trop grand accélère la convergence mais dilue l'information de coût. L'article fixe $\gamma = 0.1$ et $T = 50$ itérations comme compromis empirique ; nous quantifions ce compromis expérimentalement en section 6.

4 Description détaillée de la méthode (OTA)

4.1 Formulation du problème d’assignation comme transport optimal

Soit une image contenant m objets vérité-terrain $\{gt_i\}_{i=1}^m$ et n ancrs $\{a_j\}_{j=1}^n$ (à travers tous les niveaux de la pyramide de caractéristiques, FPN). Chaque gt_i est vu comme un *fournisseur* disposant de k_i unités de « label positif », et chaque ancre a_j comme un *demandeur* ayant besoin d’exactly une unité de label ($d_j = 1$).

4.2 Coût de transport (Eq. 2 de l’article)

Le coût de transport d’un label positif de gt_i vers l’ancre a_j est la somme pondérée des pertes de classification et de régression que cette assignation induirait :

$$c_{ij}^{fg} = \mathcal{L}_{\text{cls}}(P_j^{\text{cls}}(\theta), G_i^{\text{cls}}) + \alpha \mathcal{L}_{\text{reg}}(P_j^{\text{box}}(\theta), G_i^{\text{box}}),$$

où P_j^{cls} , P_j^{box} sont respectivement le score de classe et la boîte prédits pour l’ancre j , G_i^{cls} , G_i^{box} la classe et la boîte vérité-terrain de gt_i , $\mathcal{L}_{\text{cls}}$ une perte d’entropie croisée (typiquement Focal Loss [7]), $\mathcal{L}_{\text{reg}}$ une perte d’IoU (ou GIoU [10]), et α un coefficient d’équilibrage ($\alpha = 1.5$ dans l’article).

4.3 Le fond comme fournisseur supplémentaire (Eq. 3-4)

Comme la majorité des ancrs doivent être étiquetées négatives, l’article introduit un fournisseur supplémentaire, le *fond* (*background*), qui ne fournit que des labels négatifs. Le coût associé ne comporte que le terme de classification (vers la classe « fond ») :

$$c_j^{bg} = \mathcal{L}_{\text{cls}}(P_j^{\text{cls}}(\theta), \emptyset).$$

En empilant c_j^{bg} comme dernière ligne de c^{fg} , on obtient la matrice de coût complète $c \in \mathbb{R}^{(m+1) \times n}$. Le vecteur d’offre est alors

$$s_i = \begin{cases} k_i & \text{si } i \leq m \\ n - \sum_{i=1}^m k_i & \text{si } i = m + 1. \end{cases}$$

4.4 Estimation dynamique de k (*Dynamic k Estimation*)

Le nombre approprié de labels positifs k_i pour un objet devrait dépendre de sa taille, sa forme, son niveau d’occlusion — des facteurs difficiles à modéliser directement. L’article propose une heuristique simple mais efficace : pour chaque gt_i , sélectionner les q ancrs de plus haute IoU avec gt_i , et sommer ces valeurs d’IoU pour obtenir k_i (arrondi à l’entier le plus proche, avec $q = 20$ dans l’article). L’intuition : plus un objet a d’ancres qui le régressent déjà bien, plus il « mérite » de labels positifs pour continuer à converger efficacement.

4.5 Center Prior

Pour éviter d’exposer l’optimisation à un trop grand nombre d’ancres ambiguës dès le début de l’entraînement (ce qui déstabiliserait la convergence), l’article restreint, pour chaque gt_i , l’ensemble des candidats positifs éligibles aux r^2 ancrs les plus proches du centre de gt_i (par niveau de la pyramide), les autres recevant un coût constant additionnel important dans la matrice de coût.

4.6 Décodage de l'assignation

Une fois le plan de transport $\pi^* \in \mathbb{R}^{(m+1) \times n}$ obtenu par Sinkhorn-Knopp, chaque ancre a_j est assignée au fournisseur (un gt_i , ou le fond) qui lui transporte la plus grande quantité de label : $\text{assign}(j) = \arg \max_i \pi_{ij}^*$.

4.7 Traitement des ancres ambiguës

L'article définit une ancre comme *ambiguë* si $\max_i \pi_{ij}^* < 0.9$ — c'est-à-dire si le plan de transport ne « penche » pas clairement vers un seul fournisseur. Contrairement aux heuristiques Min Area (assigner au plus petit objet), Max IoU (assigner à l'IoU la plus grande) ou Min Loss (assigner au coût minimal), qui résolvent l'ambiguïté *ancre par ancre indépendamment*, OTA la résout *globalement* via l'optimisation du coût total de transport : si plusieurs gt « se disputent » la même ancre, l'algorithme la répartit ou l'attribue selon le principe du coût global minimal, ce qui, empiriquement dans l'article, réduit fortement le nombre d'ancres réellement ambiguës.

4.8 Algorithme complet

Listing 1 – Algorithme d'assignation OTA (Algorithme 1 de l'article, pseudo-code)

```
def ota_assign(image, anchors, gts, gamma=0.1, T=50, alpha=1.5, r=..., q=20):
    m, n = len(gts), len(anchors)
    P_cls, P_box = forward(image, anchors) # scores et boites predites
    iou = box_iou(gts, P_box)
    k = dynamic_k_estimation(iou, q) # section 3.3
    c_cls = focal_loss(P_cls, gts.classes)
    c_reg = iou_loss(P_box, gts.bboxes)
    c_cp = center_prior_penalty(anchors, gts, r) # section 3.3
    c_fg = c_cls + alpha * c_reg + c_cp
    c_bg = focal_loss(P_cls, background_class)
    cost = stack([c_fg, c_bg]) # (m+1, n)
    s = concat([k, n - sum(k)])
    d = ones(n)
    pi = sinkhorn_knopp(cost, s, d, gamma, T) # Eq. 10
    return decode_assignment(pi) # argmax par colonne
```

5 Implémentation

L'implémentation est écrite en Python 3, avec NumPy pour le calcul matriciel et SciPy pour la validation (résolution exacte du programme linéaire de référence). Aucune dépendance à un framework de deep learning n'est nécessaire pour l'algorithme d'assignation lui-même (qui opère sur des coûts déjà calculés) ; en environnement de production, ces coûts proviendraient bien sûr des sorties (scores, boîtes) d'un réseau réellement entraîné.

5.1 Structure du code

- `code/ot_assignment.py` — cœur de l'algorithme : `sinkhorn_knopp` (itération, Eq. 10), `build_cost_matrix` (Eq. 2-4, avec Center Prior), `dynamic_k_estimation` (section 3.3), `decode_assignment`, `ambiguous_anchor_mask`, ainsi qu'un calcul d'IoU géométrique exact (`box_iou`).
- `code/baselines.py` — heuristiques de comparaison : Min Area, Max IoU, Min Loss (section 4.2 de l'article).

- `code/experiment_ambiguous_anchors.py` — scénario synthétique contrôlé, génération des figures et tableaux.
- `code/tests/test_sinkhorn.py` — validation de Sinkhorn-Knopp contre un solveur LP exact (`scipy.optimize.linprog`).
- `code/tests/test_geometry.py` — tests unitaires de `box_iou` (cas connus, symétrie).

5.2 Extrait : itération de Sinkhorn-Knopp

Listing 2 – Cœur de l’itération de Sinkhorn-Knopp, traduction directe de l’Eq. 10

```
def sinkhorn_knopp(cost, s, d, gamma=0.1, n_iters=50):
    M = np.exp(-cost / gamma)
    u = np.ones(cost.shape[1])
    v = np.ones(cost.shape[0])
    for _ in range(n_iters):
        u = d / (M.T @ v)
        v = s / (M @ u)
    return np.diag(v) @ M @ np.diag(u)
```

5.3 Validation par comparaison à un solveur exact

Puisqu’il n’existe pas, à notre connaissance, de « vérité-terrain » triviale pour vérifier une implémentation de Sinkhorn-Knopp autrement que par ses propriétés mathématiques, nous la validons en la comparant à la solution **exacte** du programme linéaire sous-jacent (Eq. 1), résolue indépendamment par `scipy.optimize.linprog` [14] (méthode `highs`). C’est un test de correction bien plus fort qu’une simple relecture de code : toute erreur de signe, d’indexation, ou de formule serait détectée par un écart significatif au coût optimal exact.

6 Expérimentations

6.1 Validation numérique de Sinkhorn-Knopp

Nous générons des problèmes de transport aléatoires ($m = 3$ fournisseurs, $n = 12$ demandeurs, coûts uniformes aléatoires, offres/demandes entières aléatoires compatibles), résolvons chacun par Sinkhorn-Knopp ($\gamma = 0.1$, 1000 itérations) et par `linprog` (solution exacte), et comparons le coût total obtenu ainsi que le résidu des contraintes marginales.

Résultats réels (8 essais aléatoires, graine fixée) : résidu marginal maximal observé 2.1×10^{-6} (convergence numérique quasi-parfaite), écart relatif au coût optimal exact compris entre 0.16 % et 0.73 % selon les essais (moyenne ≈ 0.55 %) — un écart entièrement imputable au terme de régularisation entropique ($\gamma = 0.1$), et non à une erreur d’implémentation.

6.2 Compromis γ / nombre d’itérations

Nous étudions ensuite l’effet de $\gamma \in \{1.0, 0.5, 0.1, 0.05, 0.01\}$ à budget d’itérations *fixe* (300). Les résultats réels obtenus sont :

Ce résultat, honnêtement rapporté, est riche d’enseignement : pour $\gamma = 0.1$, l’algorithme converge parfaitement (résidu $\sim 10^{-16}$) et approche le coût optimal exact à 1 % près — cela justifie *a posteriori* le choix de $\gamma = 0.1$ fait par les auteurs de l’article. En revanche, pour γ trop petit (0.05, 0.01) à *budget d’itérations inchangé*, le résidu marginal explose (l’algorithme n’a pas eu le temps de converger, car les coefficients $\exp(-c_{ij}/\gamma)$ deviennent très contrastés) et l’« écart au LP exact » négatif qui en résulte n’est pas une optimalité réelle mais un artefact de non-convergence (le plan obtenu, infaisable, ne respecte plus les contraintes marginales).

TABLE 1 – Effet de γ sur l'écart au LP exact et la « netteté » du plan de transport, à budget d'itérations fixe (300).

γ	Résidu marginal	Écart au LP exact	Netteté moyenne
1.00	2.2×10^{-16}	32.7 %	0.573
0.50	4.4×10^{-16}	15.1 %	0.723
0.10	4.4×10^{-16}	1.0 %	0.944
0.05	9.7×10^{-1}	−35.0 %	0.874
0.01	2.0×10^0	−83.1 %	0.500

Ce compromis γ /nombre d'itérations, bien réel et bien documenté dans notre code de test, est discuté plus en détail en section 8.

6.3 Scénario synthétique d'ancres ambiguës

Rappel de l'avertissement méthodologique : en l'absence de GPU, de PyTorch et d'accès à COCO, ce scénario est **entièrement synthétique** : deux boîtes vérité-terrain se chevauchant partiellement (analogue à la Figure 1 de l'article) et une grille régulière de $25 \times 25 = 625$ ancres ponctuelles (analogue à un détecteur *anchor-free* comme FCOS). Les scores de confiance et les « qualités de régression » par ancre sont **simulés** par une fonction décroissante de la distance au centre de l'objet le plus proche, plus un bruit gaussien, imitant un détecteur *partiellement entraîné* (et non un détecteur réel). Ce choix nous permet de tester fidèlement l'*algorithme* d'assignation — ce qui est l'objet du sujet — sans prétendre simuler un vrai réseau de neurones.

La figure 1 montre les cartes d'assignation obtenues avec les quatre stratégies (Min Area, Max IoU, Min Loss, OTA) pour un rayon de Center Prior $r = 15$.




FIGURE 1 – Cartes d'assignation synthétiques (deux objets se chevauchant, 625 ancres). Chaque couleur correspond à l'un des deux objets ; gris = fond.

7 Résultats

7.1 Dynamic k et nombre d'ancres ambiguës

Sur ce scénario, l'estimation dynamique donne $k_{gt_0} = k_{gt_1} = 14$ (résultat réel, reproductible). Le tableau 2 et la figure 2 présentent le nombre d'ancres ambiguës (au sens de l'article, $\max_i \pi_{ij}^* < 0.9$ pour OTA ; candidates positives pour ≥ 2 gt simultanément pour les heuristiques) en fonction du rayon r du Center Prior.

TABLE 2 – Nombre d’ancres ambiguës en fonction du rayon r du Center Prior (scénario synthétique, valeurs réelles).

r	Ambiguës (OTA)	Ambiguës (candidates multiples, heuristiques)	k (gt0, gt1)
3	5	0	(14, 14)
6	1	0	(14, 14)
10	0	0	(14, 14)
15	6	0	(14, 14)
25	15	0	(14, 14)
40	15	2	(14, 14)




FIGURE 2 – Nombre d’ancres ambiguës en fonction du rayon r du Center Prior (scénario synthétique).

7.2 Lecture des résultats

Deux observations, honnêtement rapportées :

- **Tendance générale croissante avec r .** À mesure que r augmente, davantage d’ancres deviennent candidates positives plausibles pour les deux objets (dont les régions centrales se chevauchent partiellement), ce qui est cohérent avec l’observation qualitative de l’article (Tableau 2) : plus le candidat set est large, plus le potentiel d’ambiguïté croît. La légère non-monotonie observée ($r = 15$ légèrement supérieur à $r = 10$, puis palier à $r = 25-40$) s’explique par la géométrie discrète de notre scénario synthétique (grille 25×25 , deux boîtes de tailles fixes) et le seuil discret de la définition de l’ambiguïté, plutôt que par un phénomène général.
- **Les heuristiques rapportent presque toujours zéro ambiguïté, y compris quand OTA en trouve.** Ceci s’explique par la définition différente de l’ambiguïté pour les deux familles de méthodes : pour les heuristiques, une ancre n’est jugée « candidate multiple » que si son IoU/qualité dépasse un seuil (0.3) simultanément pour les deux objets ET qu’elle est parmi les r plus proches des deux centres — une condition stricte, rarement remplie ici du fait de la distance entre les deux centres. OTA, en revanche, détecte une ambiguïté dès que le plan de transport ne « tranche » pas nettement

($\max_i \pi_{ij}^* < 0.9$), un critère plus sensible qui capture des cas où l’ancre reçoit une part significative de labels de *deux* fournisseurs sans que l’un ne domine. Cette différence de sensibilité est elle-même un résultat intéressant : elle illustre concrètement pourquoi l’article revendique une bien meilleure *détection* de l’ambiguïté par OTA – le critère continu du plan de transport voit une ambiguïté « douce » que les heuristiques à seuil dur ignorent purement et simplement.

8 Analyse critique

8.1 Fidélité par rapport à l’article original

Ce rapport implémente fidèlement le *mécanisme algorithmique* d’OTA [3] : la formulation du transport optimal (Eq. 1), la construction du coût (Eq. 2-4), l’itération de Sinkhorn-Knopp (Eq. 5-11, Annexe A.1), le Dynamic k et le Center Prior (section 3.3). Cette implémentation est validée numériquement de façon indépendante (comparaison à un solveur LP exact). En revanche, ce rapport **ne reproduit pas** les résultats de détection de l’article (AP sur COCO/CrowdHuman, Tableaux 1 à 6), pour la raison assumée et documentée dès l’introduction : l’environnement d’exécution ne permet pas d’entraîner un détecteur profond à cette échelle (pas de GPU, pas de PyTorch, pas d’accès à COCO). Les résultats numériques présentés dans ce rapport (validation Sinkhorn-Knopp, scénario synthétique d’ancres ambiguës) sont **tous réels et reproductibles**, mais portent sur des problèmes construits pour tester l’algorithme, non sur un jeu de données de détection réel.

8.2 Limites de la méthode (et de notre validation)

- **Coût de l’itération de Sinkhorn-Knopp.** Bien que très inférieur à un solveur LP générique, le coût de T itérations de produits matriciels $O(T \cdot m \cdot n)$ reste non négligeable lorsque n (nombre d’ancres) atteint plusieurs dizaines de milliers par image (comme dans un vrai FPN multi-échelle) – l’article rapporte un surcoût d’entraînement de moins de 20 %, ce que nous ne pouvons pas vérifier directement sans réseau réel.
- **Sensibilité au couple (γ, T) .** Comme quantifié en section 6, un γ trop petit à budget d’itérations fixe conduit à une non-convergence pure et simple (résidu marginal explosif), pas seulement à une perte de précision graduelle – un piège pratique pour quiconque réimplémenterait la méthode sans validation indépendante comme la nôtre.
- **Notre construction synthétique des coûts cls/reg** (section 6.3) est une simplification assumée : dans l’article, ces coûts proviennent des sorties réelles d’un réseau en cours d’entraînement, avec toute la complexité et la non-stationnarité que cela implique (les coûts évoluent à chaque itération d’entraînement). Notre simulation statique, bien que raisonnable pour tester l’algorithme d’assignation lui-même, ne capture pas cette dynamique.
- **Absence de validation à l’échelle réelle.** Sans reproduire l’entraînement complet, nous ne pouvons pas confirmer indépendamment les gains d’AP rapportés par l’article (+0.9 à +1.2 point d’AP selon les configurations, Tableau 1 de l’article) ; nous rapportons ces chiffres comme des résultats *de l’article*, non comme des résultats que nous avons nous-mêmes reproduits.

8.3 Pistes d’amélioration

- **Reproduction à l’échelle réelle**, dès qu’un GPU et un accès à COCO/CrowdHuman sont disponibles : entraîner un FCOS-ResNet-50 avec et sans OTA, pour confirmer directement les gains d’AP rapportés par l’article.

- **Coûts cls/reg dynamiques** dans le scénario synthétique : faire évoluer les scores simulés au fil d’itérations successives (simulant un entraînement), pour étudier comment le nombre d’ancres ambiguës évolue au cours de l’entraînement, comme le suggèrent implicitement les auteurs (stabilisation en début d’entraînement grâce au Center Prior).
- **Accélération GPU de Sinkhorn-Knopp** (par exemple via CuPy ou PyTorch), pour mesurer directement le surcoût d’entraînement sur un détecteur réel, comme rapporté par l’article (moins de 20 %).
- **Extension à un plus grand nombre d’objets et de niveaux de pyramide (FPN)**, pour étudier le passage à l’échelle du scénario synthétique d’ancres ambiguës au-delà du cas à deux objets étudié ici.

9 Conclusion

Ce rapport a présenté, formalisé et implémenté fidèlement l’algorithme d’assignation par Transport Optimal (OTA) [3] : la formulation du problème de transport, la construction du coût cls+reg avec Center Prior, l’estimation dynamique de k , et la résolution par itération de Sinkhorn-Knopp. Cette implémentation a été validée numériquement contre un solveur de programmation linéaire exact (écart relatif $< 1\%$ pour les paramètres de l’article, convergence quasi-parfaite des contraintes marginales), et son comportement qualitatif face à l’ambiguïté a été étudié sur un scénario synthétique contrôlé, où elle détecte des ambiguïtés « douces » invisibles aux heuristiques à seuil dur (Min Area, Max IoU, Min Loss). Conformément à l’exigence de ne pas inventer de résultats, ce rapport n’a **pas** tenté de reproduire les scores d’AP de l’article sur COCO/CrowdHuman, faute de GPU, de framework de deep learning et d’accès réseau à ces jeux de données dans l’environnement d’exécution — une limitation clairement assumée plutôt que dissimulée. Les pistes naturelles de poursuite de ce travail sont l’entraînement à l’échelle réelle dès que les ressources le permettront, et l’étude de la dynamique temporelle de l’ambiguïté au cours de l’entraînement.

Références

- [1] Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. *arXiv preprint arXiv :2005.12872*, 2020.
- [2] Marco Cuturi. Sinkhorn distances : Lightspeed computation of optimal transport. *Advances in Neural Information Processing Systems (NeurIPS)*, 26 :2292–2300, 2013.
- [3] Zheng Ge, Songtao Liu, Zeming Li, Osamu Yoshie, and Jian Sun. OTA : Optimal transport assignment for object detection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [4] Zheng Ge, Jianfeng Wang, Xin Huang, Songtao Liu, and Osamu Yoshie. LLA : Loss-aware label assignment for dense pedestrian detection. *arXiv preprint arXiv :2101.04307*, 2021.
- [5] Kang Kim and Hee Seok Lee. Probabilistic anchor assignment with IoU prediction for object detection. *arXiv preprint arXiv :2007.08103*, 2020.
- [6] Harold W. Kuhn. The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1-2) :83–97, 1955.
- [7] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pages 2980–2988, 2017.

- [8] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO : Common objects in context. *European Conference on Computer Vision (ECCV)*, pages 740–755, 2014.
- [9] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster R-CNN : Towards real-time object detection with region proposal networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 91–99, 2015.
- [10] Hamid Rezatofighi, Nathan Tsoi, JunYoung Gwak, Amir Sadeghian, Ian Reid, and Silvio Savarese. Generalized intersection over union : A metric and a loss for bounding box regression. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 658–666, 2019.
- [11] Shuai Shao, Zijian Zhao, Boxun Li, Tete Xiao, Gang Yu, Xiangyu Zhang, and Jian Sun. Crowdhuman : A benchmark for detecting human in a crowd. *arXiv preprint arXiv :1805.00123*, 2018.
- [12] Zhi Tian, Chunhua Shen, Hao Chen, and Tong He. FCOS : Fully convolutional one-stage object detection. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 9627–9636, 2019.
- [13] Cédric Villani. Optimal transport : Old and new. *Springer, Grundlehren der mathematischen Wissenschaften*, 338, 2009.
- [14] Pauli Virtanen, Ralf Gommers, Travis E. Oliphant, et al. SciPy 1.0 : Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, pp. 261–272, 2020.
- [15] Shifeng Zhang, Cheng Chi, Yongqiang Yao, Zhen Lei, and Stan Z. Li. Bridging the gap between anchor-based and anchor-free detection via adaptive training sample selection. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 9759–9768, 2020.
- [16] Xiaosong Zhang, Fang Wan, Chang Liu, Rongrong Ji, and Qixiang Ye. Freeanchor : Learning to match anchors for visual object detection. *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.
- [17] Benjin Zhu, Jianfeng Wang, Zhengkai Jiang, Fuhang Zong, Songtao Liu, Zeming Li, and Jian Sun. Autoassign : Differentiable label assignment for dense object detection. *arXiv preprint arXiv :2007.03496*, 2020.